Anotações das Aulas de Ciência de Dados

Fundamentos Matemáticos, Teoria de Aprendizado
e Aplicações em Python

—
—

18 de dezembro de 2025

Sumário

Sumário **2**

I Introdução **4**

1 Motivação **5**

II Fundamentos Matemáticos **6**

2 Linear Algebra **7**
2.1 Vetores 8
2.2 Matrizes 9
2.3 Dot Product 10

3 Fundamentos do Cálculo **12**

4 Estatística e Probabilidade **13**

III Aprendendo a partir dos dados **14**

5 Learning Problem **15**

6 Regressão Linear **19**

7 Regressão Logística **20**

Referências Bibliográficas **21**

Parte I

Introdução

Capítulo 1

Motivação

- Por que estudar fundamentos?

Parte II

Fundamentos Matemáticos

Capítulo 2

Linear Algebra

Para conseguirmos caminhar juntos neste livro, precisamos estabelecer intuições de algebra linear entendendo sobre matrizes, vetores e suas operações.

2.1 Vetores

Os vetores, são estruturas unidimensionais que podem armazenar informações e serão representados com letras minúsculas em negrito, como $\mathbf{x}$ e $\mathbf{w}$ e serão em formato de coluna.

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_d \end{bmatrix}_{D\times 1}, \quad \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix}_{D\times 1} \tag{2.1}$$

Para conseguirmos entender e visualizar melhor o que seria um vetor coluna, podemos imaginar que um vetor é uma lista de valores empilhados verticalmente, onde cada valor individual é chamado de componente do vetor. Como por exemplo, imagine que um vetor $\mathbf{v}$ trata-se de um apartamento e nesse apartamento temos várias informações como quantidade de quartos, banheiros, m^2.

$$\mathbf{v} = \begin{bmatrix} v_0 \\ v_1 \\ \vdots \\ v_d \end{bmatrix}_{D\times 1} \begin{matrix} \text{quartos} \\ \text{banheiros} \\ \vdots \\ \text{m}^2 \end{matrix} \tag{2.2}$$

2.2 Matrizes

As matrizes representam apartamentos nas linhas e cada coluna representam informações do apartamento como as outras que vimos antes. Ou seja, se cada apartamento tem 5 informações e pesquisamos por 10 apartamentos, teremos uma matriz de 10 linhas e 5 colunas. Se as 5 informações de cada apartamento for representado em um vetor coluna, para construir a matriz de dados, podemos empilhar em cada linha as transpostas desses vetores colunas.

$$X = \begin{bmatrix} — \mathbf{x}_1^T — \\ — \mathbf{x}_2^T — \\ \vdots \\ — \mathbf{x}_n^T — \end{bmatrix} = \begin{bmatrix} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_D \\ | & | & & | \end{bmatrix}_{N \times D} \tag{2.3}$$

2.3 Dot Product

O Dot Product é o somatório da multiplicação entre dois vetores que vai resultar em um número real. Podemos entender o dot product como uma forma de fazer uma combinação linear entre dois vetores.

$$\mathbf{u}^T \times \mathbf{x} = [u_1 u_2 ... u_d]^T_{1\times D} \times \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_d \end{bmatrix}_{D\times 1} \tag{2.4}$$

$$= u_0 x_0 + u_1 x_1 + u_2 x_2 ... + u_d x_d$$

$$= \sum_{i=1}^{d} u_i x_i$$

Propriedades importantes do dot product:

- Comutativa: $\mathbf{u}^T\mathbf{x} = \mathbf{x}^T\mathbf{u}$
- Distributiva: $\mathbf{u}^T(\mathbf{x} + \mathbf{v}) = \mathbf{u}^T\mathbf{x} + \mathbf{u}^T\mathbf{v}$

Além dessa interpretação algébria, podemos interpretar o dot product de forma geométrica. Todo vetor tem as propriedades de magnitude e direção. A magnitude pode ser entendida como o tamanho do vetor, e a direção como o ângulo que o vetor faz com o eixo horizontal.

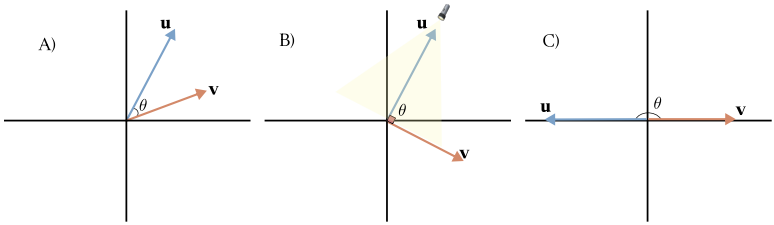

Figura 2.1:

O dot product representa a multiplicação das magnitudes dos vetores e o cosseno do ângulo entre eles.

$$\mathbf{u} \cdot \mathbf{v} = |\mathbf{u}||\mathbf{v}| \cos(\theta)$$

Quando os vetores são otogonais, ou seja, formam um ângulo de 90 graus entre eles $\theta = 90°$, o $\cos(\theta)$ será igual a zero. Esse cenário mostrado na 2.1-B descreve o caso onde a projeção de um vetor no outro é nula. Outro caso interessante é quando os vetores estão em direções opostas, ou seja, formam um ângulo de 180 graus entre eles $\theta = 180°$. Nesse caso, o $\cos(\theta)$ será igual a -1, e o dot product resultará em um valor negativo. Esse cenário é ilustrado na 2.1-C, onde a projeção de um vetor no outro é negativa.

Capítulo 3

Fundamentos do Cálculo

Capítulo 4

Estatística e Probabilidade

Parte III

Aprendendo a partir dos dados

Capítulo 5

Learning Problem

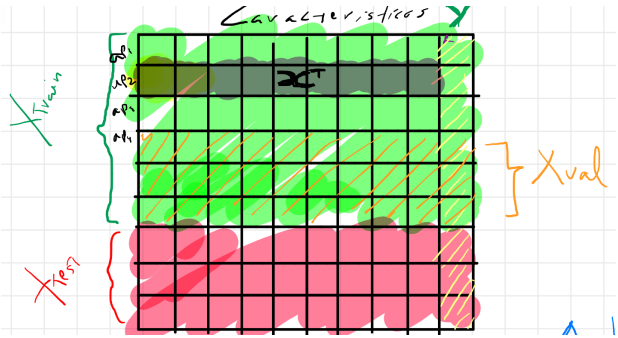

Figura 5.1:

Coluna Y são os preços de apartamentos, as outras são características dos apartamentos, m², número de quartos e entre outros.

$$\mathbf{f} = \{f_\theta \mid \theta \in \Theta\}$$

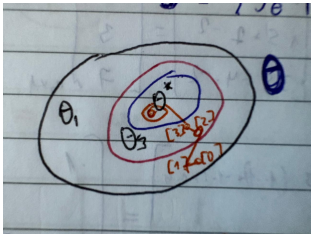

Figura 5.2:

$$\mathbf{f}_\theta : \mathbb{R}^D \to \mathbb{R}^1$$

$$\{\mathbf{x^T} | \mathbf{x^T} \in \mathbb{R}^{1\times D}\} \to \{y \in \mathbb{R}^{1\times 1}\}$$

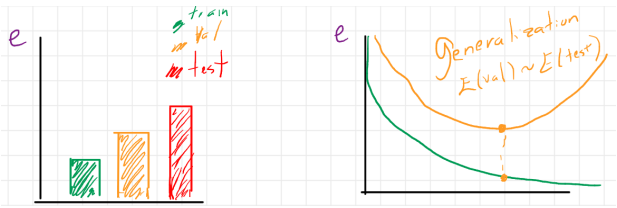

Figura 5.3:

$$\mathbf{y} = X\mathbf{w} \quad ; \mathbf{y} = \begin{bmatrix} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_d \\ | & | & & | \end{bmatrix}_{N \times D} \cdot \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix}_{D \times 1}$$

Vamos continuar pensando que a matriz X onde cada linha é um apartamento e cada coluna é alguma informação do apartamento. Logo, estamos querendo saber o preço desses apartamentos a partir das informações, será que apartamentos com mais quarto são mais caros por exemplo. Então temos que o $\mathbf{w}$ é um vetor coluna de pesos, pense que cada informação do apartamento tem um peso associado a ele que vai ser importante para o cálculo do preço final. Então $\mathbf{y}$ é um vetor coluna que contém os preços de todos os apartamentos.

Mas afinal quem é $\mathbf{w}$? Bom, temos dois w, um deles é que existe um $\mathbf{w}^*$ que é um conjunto de pesos que vai conseguir prever perfeitamente todos os preços dos apartamentos corretamente e que assim vai gerar o $\mathbf{y} = X\mathbf{w}^*$. Como esse $\mathbf{w}^*$ é desconhecido, tentamos encontrar um $\hat{\mathbf{w}}$ que tenta se aproximar ao máximo de $\mathbf{w}^*$ e que assim vai gerar o $\hat{\mathbf{y}} = X\hat{\mathbf{w}}$, nota-se que o $\hat{\mathbf{y}}$ não vai conseguir prever os preços de todos os apartamentos corretamente como o $\mathbf{y}$ mas será o mais próximo dele possível.

Como encontrar o $\mathbf{w}$?

- X é uma matriz quadrada $X_{D\times D}$

$$
\begin{aligned}
\mathbf{y} &= X_{D\times D} \cdot \mathbf{w}_{D\times 1} \\
X^{-1}_{D\times D} \cdot \mathbf{y} &= X^{-1}_{D\times D} \cdot X_{D\times D} \cdot \mathbf{w}_{D\times 1} \\
X^{-1}_{D\times D} \cdot \mathbf{y} &= I \cdot \mathbf{w}_{D\times 1} \\
X^{-1}_{D\times D} \cdot \mathbf{y} &= \mathbf{w}_{D\times 1} \\
X^{-1}_{D\times D} \cdot \mathbf{y} &= \mathbf{w}^{*}{}_{D\times 1} \\
\hat{\mathbf{y}} &= X_{D\times D} \cdot \mathbf{w}^{*} \\
\hat{\mathbf{y}} &= X_{D\times D} \cdot X^{-1}_{D\times D} \cdot \mathbf{y} \\
\hat{\mathbf{y}} &= I \cdot \mathbf{y} \\
\hat{\mathbf{y}} &= \mathbf{y}
\end{aligned}
\tag{5.1}
$$

Capítulo 6

Regressão Linear

Capítulo 7

Regressão Logística

Referências Bibliográficas